

Credit Risk Lakehouse - Master Plan

Projeto de portfólio profissional focado em Engenharia de Dados, Big Data, Risco de Crédito e Monitoramento de Modelos utilizando PySpark, Docker, Jupyter Notebook e arquitetura Lakehouse.

Objetivo

Construir uma plataforma de risco de crédito capaz de simular uma carteira multiproduto, processar grandes volumes de dados, gerar features para modelos, calcular métricas de risco (PD, LGD, EAD e PDD), realizar scoring e monitorar a performance dos modelos ao longo do tempo.

Produtos da Carteira

- Empréstimo Pessoal - Cartão de Crédito - Financiamento de Veículo - Consignado Cada produto possuirá comportamento de risco e LGD distintos.

Stack Tecnológica

- Docker - Apache Spark - PySpark - Jupyter Notebook - VS Code - Parquet - Python - Scikit-Learn
- Pytest - GitHub

Arquitetura Lakehouse

Raw -> Bronze -> Silver -> Gold -> Feature Store -> Modelo -> Monitoring
Bronze: dados brutos.
Silver: dados limpos e padronizados. Gold: métricas e visões analíticas. Feature Store: features para machine learning. Modelo: cálculo de PD. Monitoring: PSI, drift, AUC, KS, Gini e métricas de negócio.

Modelo de Dados

Principais entidades: Clientes Bureau de Crédito Propostas Contratos Parcelas Pagamentos
Eventos de Default

Métricas de Crédito

PD (Probability of Default) LGD (Loss Given Default) EAD (Exposure at Default) Expected Loss = PD x LGD x EAD PDD (Provisão para Devedores Duvidosos)

Monitoramento

- PSI - Data Drift - Model Drift - ROC AUC - KS - Gini - Default Rate - Bad Rate - Taxa de Aprovação

Aprendizado de Spark

Fundamentos: - SparkSession - DataFrames - Schemas - Transformations e Actions Intermediário: - Joins - Aggregations - Window Functions Avançado: - DAG - Lazy Evaluation - Catalyst Optimizer - Shuffle - Broadcast Join - Partitioning - Cache e Persist - Explain Plans - Data Skew

Estrutura do Repositório

credit-risk-lakehouse/ .github/ docker/ data/ docs/ notebooks/ src/ tests/ Com separação clara entre código produtivo, estudos, documentação e dados.

Roadmap

Sprint 0 - Arquitetura e modelagem Sprint 1 - Ambiente Docker + Spark + Jupyter Sprint 2 - Fundamentos Spark Sprint 3 - Bronze Layer Sprint 4 - Silver Layer Sprint 5 - Gold Layer Sprint 6 - Feature Engineering Sprint 7 - Modelagem de PD Sprint 8 - Monitoramento Sprint 9 - Otimização e documentação final

Princípios do Projeto

1. Pensar como engenheiro de dados, não apenas usuário de Spark.
2. Entender o motivo das decisões arquiteturais.
3. Justificar particionamentos e otimizações.
4. Evitar transformar Spark em um Pandas gigante.
5. Produzir um portfólio profissional e defensável tecnicamente.